Trabajo Práctico 3

Big Data

Agustín Acosta

Luca Armelini

Gorki Freire

Profesor: Walter Sosa

Tutora: Pilar Hüppi

Parte I: Analizando la base

La Encuesta Permanente de Hogares (EPH) es un programa nacional de producción sistemática y permanente de indicadores sociales que lleva a cabo el Instituto Nacional de Estadística y Censos (INDEC), que permite conocer las características sociodemográficas y socioeconómicas de la población. Uno de los indicadores más valiosos sobre el mercado laboral que pueden obtenerse con los datos de esta encuesta es la tasa de desocupación.

1. Utilizando información disponible en la página del INDEC, expliquen brevemente cómo se identifica a las personas desocupadas.

Respuesta: El INDEC define a las personas desocupadas cómo "aquellas que sin tener trabajo se encuentran disponibles para trabajar y han buscado activamente una ocupación en un periodo de referencia determinado" (INDEC, 2011).

Para la medición de este concepto en la EPH se considera como desocupados abiertos a todas las personas de 10 años y más que no trabajaron en la semana de referencia, estaban disponibles y buscaron activamente trabajo (enviar curriculums, responder a avisos de diarios/internet, consultar a parientes o amigos, etc.) en algún momento de los últimos treinta días. Se incluyen dentro de este grupo a las personas disponibles que no buscaron trabajo, porque ya tenían trabajo asegurado y a los suspendidos sin pago que no buscaron porque esperaban ser reincorporados. El concepto de desocupación abierta no incluye otras formas de empleo inadecuado tales como personas que realizan trabajos transitorios mientras buscan activamente una ocupación, aquellas que trabajan jornadas involuntariamente por debajo de lo normal, los ocupados en puestos por debajo de la remuneración mínima o en puestos por debajo de su calificación, ni a los desocupados que han suspendido la búsqueda por falta de oportunidades visibles de empleo, etc. Estas modalidades son también relevadas en la EPH como indicadores separados.

2. Entren a la página https://www.indec.gob.ar/ y vayan a la sección Servicios y Herramientas ->Bases de datos. Descarguen la base de microdatos de la Encuesta Permanente de Hogares (EPH) correspondiente al primer trimestre de 2005 y 2025 en formato .dta y .xls, respectivamente (una vez descargadas, las bases a usar deberán llamarse individual_T105.dta y usu_individual_T125.xls). En la página web, también encontrarán un diccionario de variables con el nombre de "Diseño de registro y estructura para las bases preliminares (hogares y personas)". Descarguen el diccionario de cada año. En estos archivos se les indica qué significa cada variable que aparece en la base de datos, en particular, en la sección de Diseño de registros de la base Personas.

Respuesta: Considerando que somos el grupo 6, se procede a trabajar con el aglomerado "Bahía Blanca-Cerri". El código del aglomerado en cuestión es 04. Se optó por unir ambas bases como dos hojas de un solo Excel. Para filtrar según aglomerado y eliminar valores carentes de sentido (Edad e Ingresos con y sin socios negativos) simplemente se empleó el comando "Filtro" de Excel. A partir de aquí se trabaja con Python.

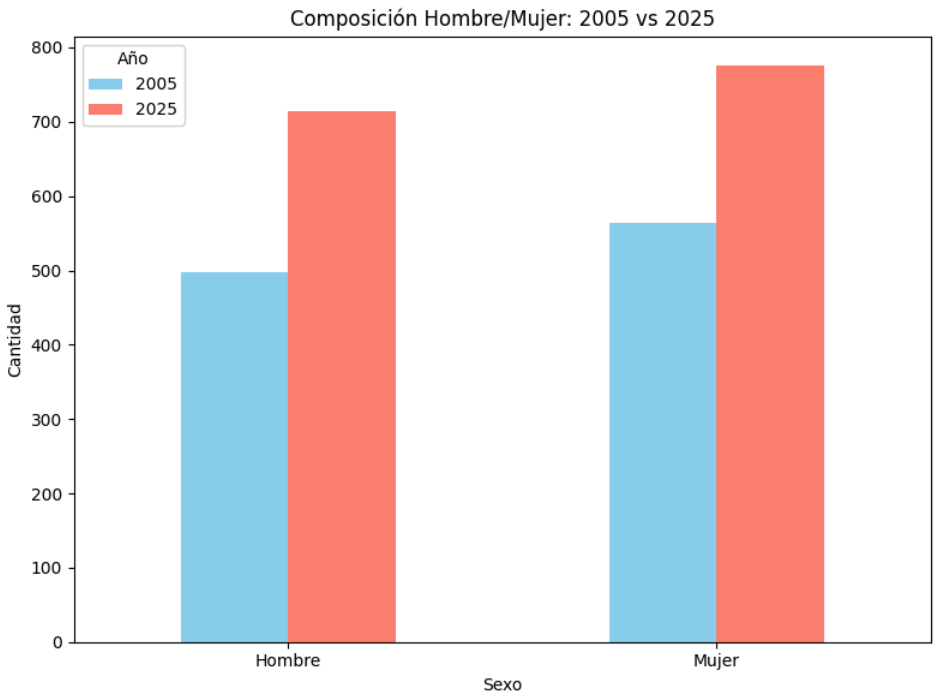

Imagen 1

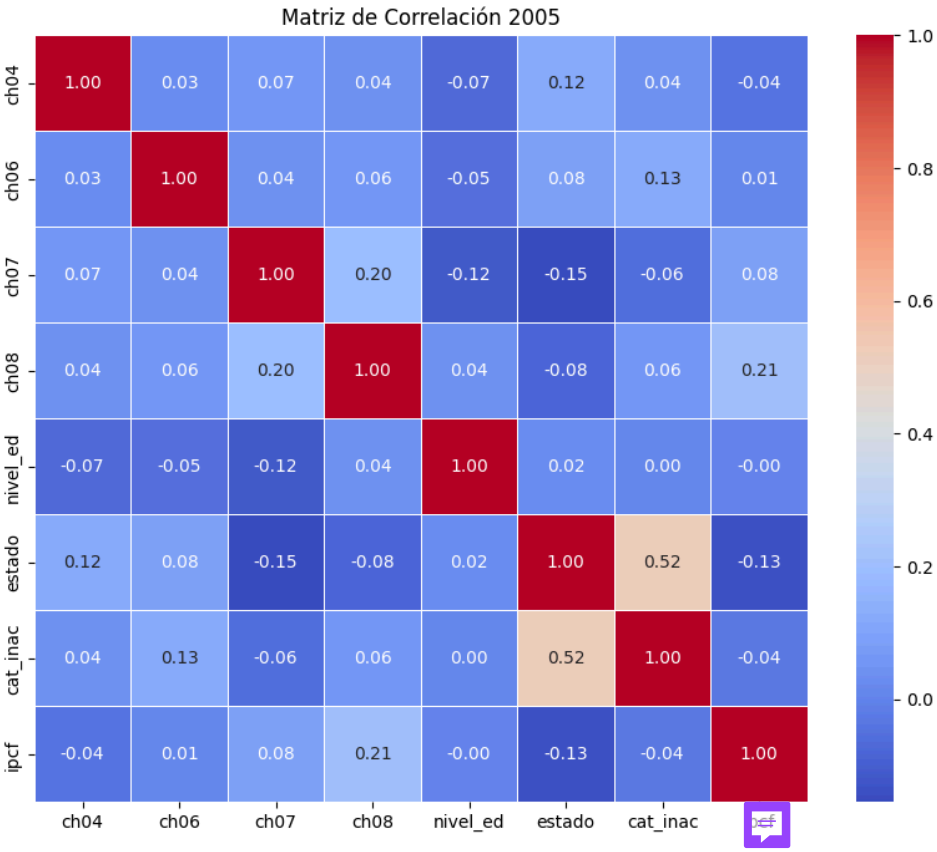

Imagen 2

La Imagen 1 muestra la composición de encuestados por sexo. Se observa una cantidad mayor de mujeres encuestadas en ambos censos. Además, la cantidad de encuestados es levemente mayor para ambos sexos en el 2025. La Imagen 2 muestra los niveles de correlación entre diversas variables presentadas en la encuesta del 2005. Dichos niveles son débiles cercanos a 0 en su mayoría. Destaca la correlación entre el nivel de educación y la condición de inactivo (0.25), es decir, que aún no forma parte del mercado laboral.

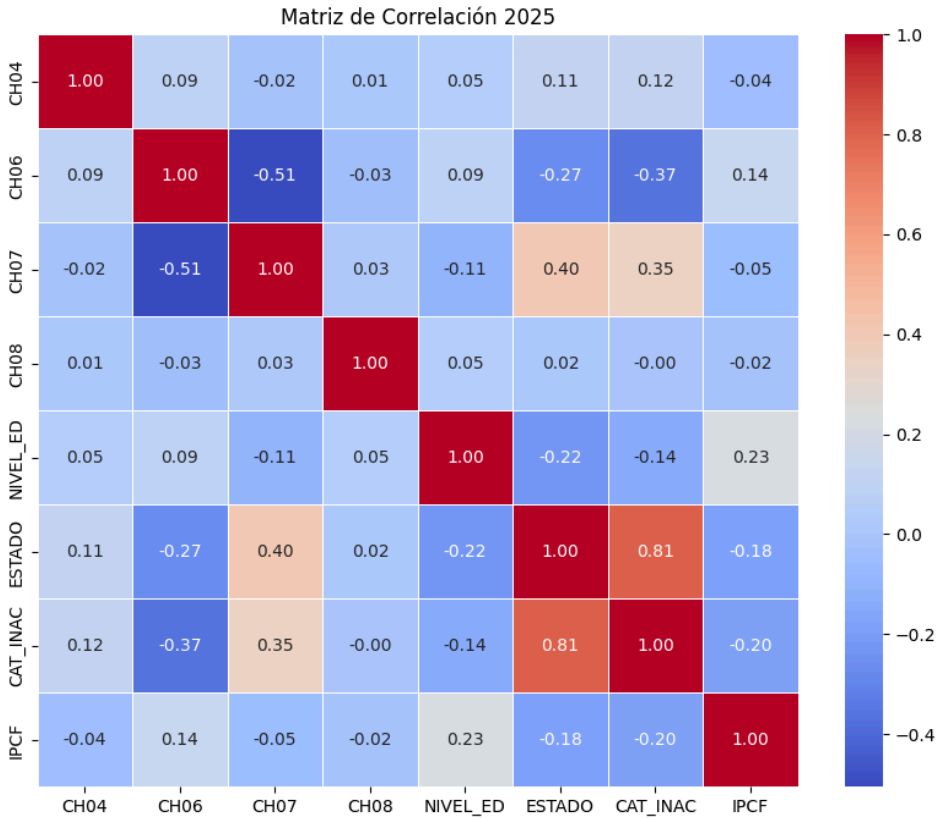

Imagen 3

Respuesta: La Imagen 3 presenta la matriz de correlación para la encuesta de 2025. A diferencia de la encuesta anterior, en este caso si se muestran correlaciones importantes. No obstante, varias de ellas tienen un valor interpretativo no relevante.

La tabla posterior denota estadísticas de los estados ocupacionales para ambos años.

Estado	**Cantidad (2005)**	**Cantidad (2025)**	**Media IPCF ARS (2005)**	**Media IPCF ARS (2025)**
Ocupado	431	642	564.9	485861.5
Desocupado	52	55	387.3	291836.6
Inactivo	457	630	421.5	332889.7

La relación entre variables se mantiene constante en el tiempo. El número de desocupados es significativamente menor a las otras dos categorías en ambas encuestas. El orden en la media de IPCF también se mantiene en las encuestas. Los hogares del integrante ocupado son los más ricos, seguidos del inactivo (probablemente financiado) y el desocupado.

3. Uno de los grandes problemas de la EPH es la creciente cantidad de hogares que no reportan sus ingresos (ver por ejemplo el siguiente informe). ¿Cuántas personas no respondieron cuál es su condición de actividad? Guarden como una base distinta llamada respondieron las observaciones donde respondieron la pregunta sobre su condición de actividad (ESTADO). Las observaciones con ESTADO=0 guárdenlas en una base bajo el nombre no respondieron.

Respuesta: Para el caso de “Bahía Blanca - Cerri”, y luego de filtrar los valores negativos requeridos en el inciso anterior, no se observan respuestas con valor 0 en la variable ESTADO en ninguna de las dos encuestas.

4. Agreguen a la base respondieron una columna llamada PEA (Población Económicamente Activa) que tome 1 si están ocupados o desocupados en ESTADO. Realicen un gráfico de barras mostrando la composición por PEA para 2005 y 2025. Comenten los resultados.

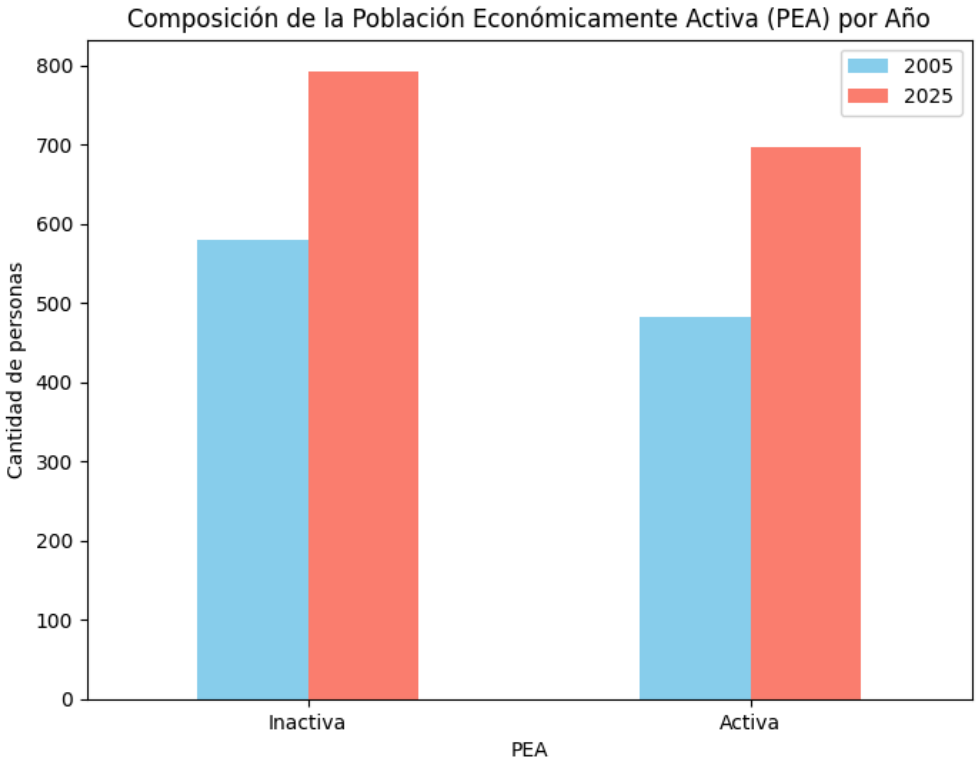

Imagen 4

Respuesta: Se observa la composición de la población activa v/s la inactiva en ambas encuestas. Si bien ambas crecen por la mayor cantidad de encuestados, en ambos casos la población inactiva es mayor que la activa, lo que implica que hay más gente fuera del mercado laboral que aquella trabajando o buscando trabajar.

5. Agreguen a la base respondieron una columna llamada PET (Población en Edad para Trabajar) que tome 1 si están la persona tiene entre 15 y 65 años cumplidos. Realicen un gráfico de barras mostrando la composición por PEA para 2005 y 2025. Comenten los resultados y compare PET con PEA.

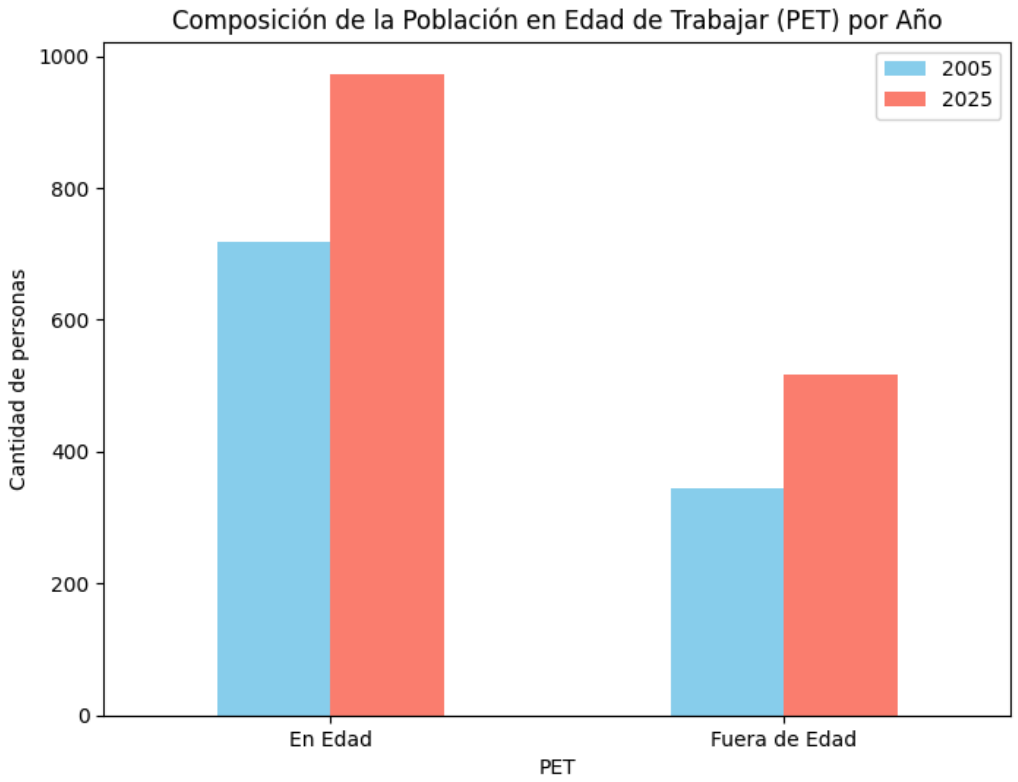

Imagen 5

Respuesta: En la imagen 5 vemos cómo se distribuye la población teniendo en cuenta si está en edad de trabajar o no. Comparando con la respuesta anterior, lo interesante es que la población en edad de trabajar supera ampliamente a aquella fuera de edad. Esto sugiere que mucha población inactiva se encuentra en edad de trabajar pero por razones ajenas a este informe no lo hace.

6. Por último, agreguen la base respondieron una columna llamada desocupado que tome 1 si está desocupada. ¿Cuántas personas están desocupadas en 2005 vs 2025?

Respuesta: La cantidad de desocupados reportada es de 52 sobre 1062 personas para el año 2005 y de 55 sobre 1491 para el año 2025. Esto implica que había un 4.9% de los encuestados desocupados en el 2005 contra un 3.69% en el 2025.

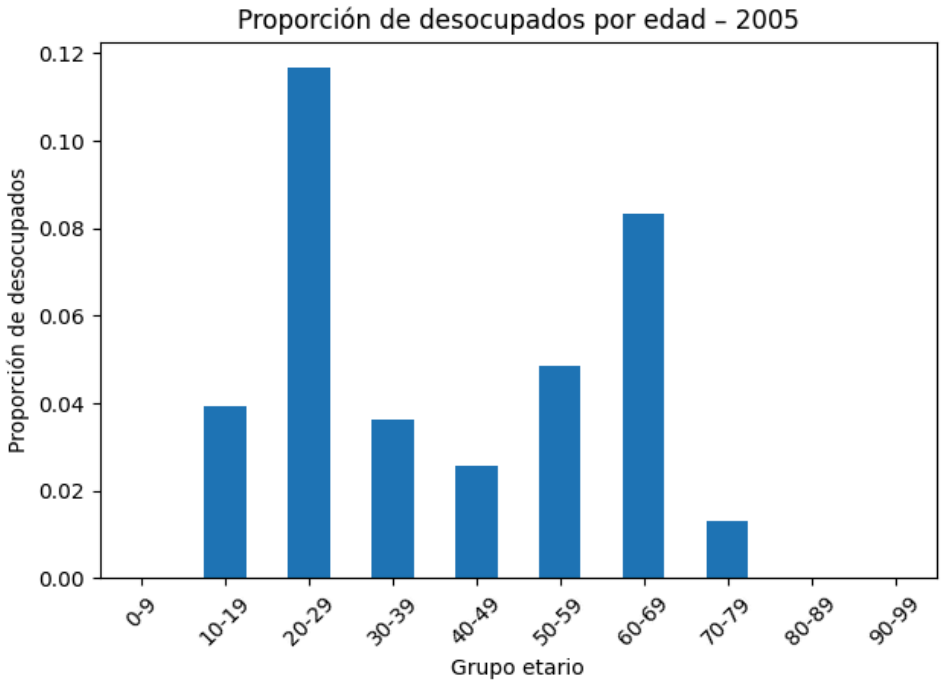

Imagen 6

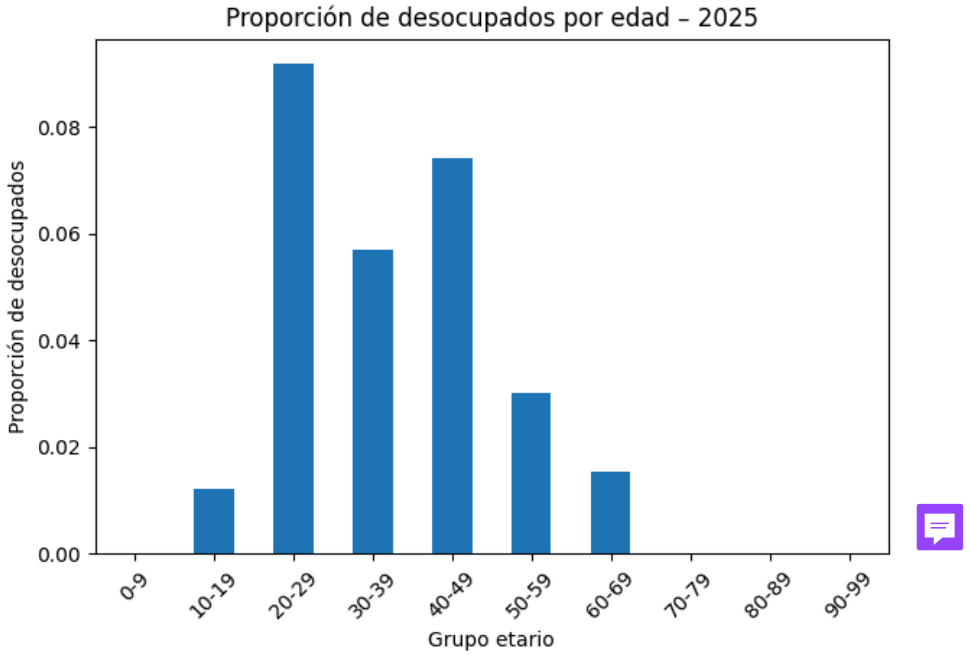

Imagen 7

Parte II: Clasificación

El objetivo de esta parte del trabajo es intentar predecir si una persona está desocupada o no utilizando distintas variables de características individuales.

1. Para cada año, partan la base respondieron en una base de prueba (test) y una de entrenamiento (train) utilizando el comando train_test_split. La base de entre namiento debe comprender el 70% de los datos, y la semilla a utilizar (random state instance) debe ser 101. Establezcan a desocupado como su variable dependiente en la base de entrenamiento (vector y). El resto de las variables serán las variables independientes (matriz X). Recuerden agregar la columna de unos (1).

Respuesta:

Para abordar el problema de clasificación del estado ocupacional, se procedió en primera instancia a la construcción del vector objetivo y la matriz de características para los periodos 2005 y 2025.

Se generó un vector binario **y** donde se asignó el valor **1** a los individuos clasificados estrictamente como "Desocupados" y **0** al resto de la muestra (ocupados, inactivos y menores). El análisis descriptivo preliminar revela un fuerte desbalance de clases en la muestra analizada: la tasa de desocupación muestral representa apenas un 4.90% en la base de 2005 y un 3.69% en la de 2025.

Para la construcción de la matriz X, se eliminaron las variables de identificación administrativa (por ej., CODUSU, NRO_HOGAR) que no aportan información predictiva estructural. Se aplicaron dos transformaciones. Primero, se transformaron las variables cualitativas mediante *one-hot encoding* (variables *dummy*), lo que resultó en una expansión dimensional significativa, particularmente en la base 2005 (529 *features*). Y segundo, se incorporó un vector columna unitario (**1**) en la primera posición de la matriz para capturar la ordenada al origen (intercepto) en los modelos lineales.

Siguiendo la metodología estándar de Machine Learning para evaluación fuera de muestra, se particionaron los datos en conjuntos de entrenamiento (70%) y prueba (30%). Se fijó una semilla aleatoria (random_state=101) para garantizar la reproducibilidad de los resultados.La estructura final de los conjuntos de datos se resume a continuación:
2005: $N_{total}=1062$. Matriz de diseño $X \in \mathbb{R}^{1062 \times 529}$
2025: $N_{total}=1490$. Matriz de diseño $X \in \mathbb{R}^{1490 \times 232}$

2. Implementen los siguientes métodos reportando luego la matriz de confusión, la curva ROC, los valores de AUC y de Accuracy de cada uno:

- Regresión logística;

- Análisis discriminante lineal;
- KNN con k =3;
- Naive Bayes.

Respuesta:

Para la predicción del estado de desocupación, se implementaron cuatro algoritmos de aprendizaje supervisado: Regresión Logística, Análisis Discriminante Lineal (LDA), K-Vecinos Más Cercanos (**k**-NN) y Naive Bayes (Gaussiano). Previo al ajuste, se realizó una depuración de la matriz de regresores eliminando aquellas columnas con información faltante (NaN) para garantizar la estabilidad computacional de los estimadores como LDA y Naive Bayes.A continuación, se presentan las métricas de desempeño para los periodos bajo análisis:

A. Regresión Logística:

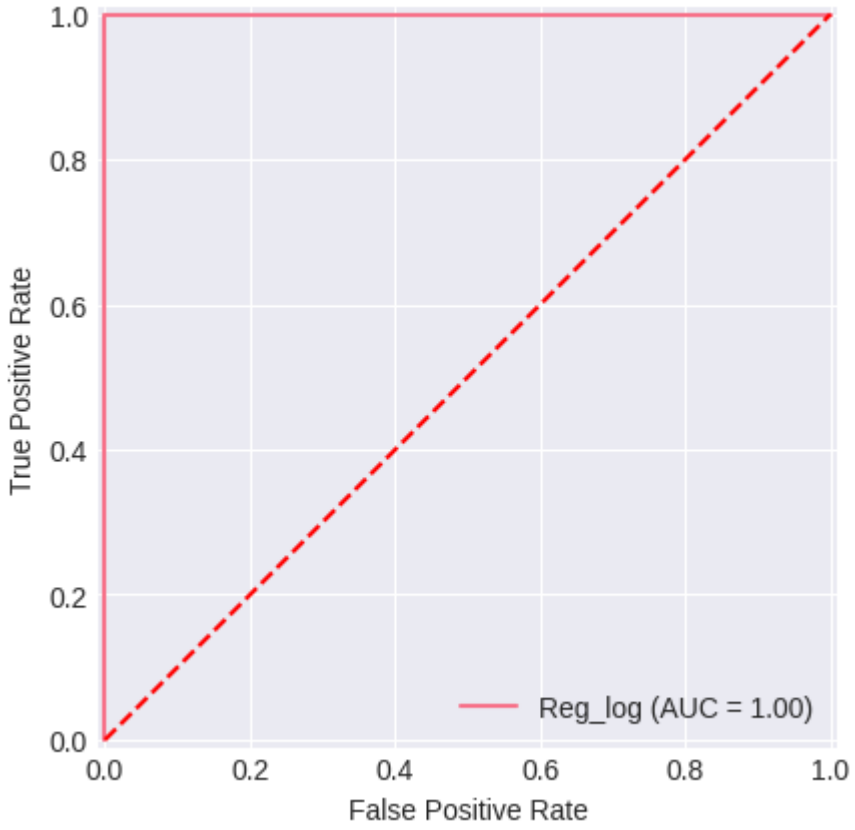

Figura 1: Curva ROC 2005.

El modelo logístico evidenció comportamientos dispares entre ambos periodos. Para el 2005, se obtuvo una separación perfecta de las clases en la muestra de prueba, con un **AUC de 1.00** y una exactitud (*Accuracy*) del **99.68%**. La matriz de confusión denota una capacidad predictiva inusualmente alta, sugiriendo que, tras la limpieza de datos, las variables remanentes capturan determinantes estructurales inequívocos del estado ocupacional en dicho año.

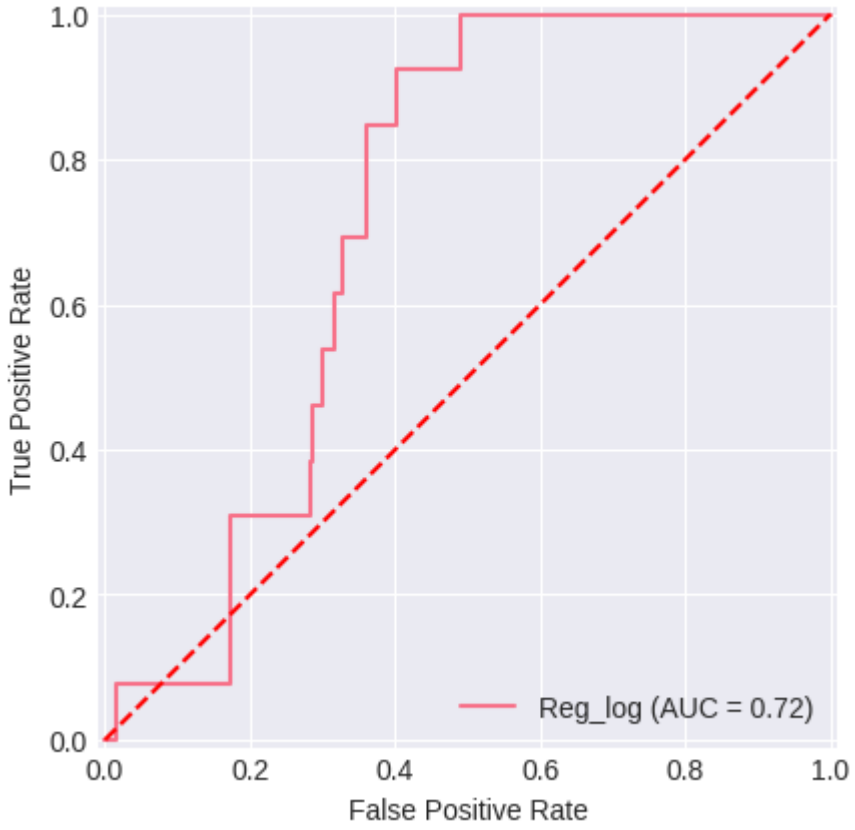

Figura 2. Curva ROC 2025.

Para el 2025, el modelo alcanzó un **AUC de 0.7187**. Si bien la exactitud global es elevada (**96.87%**), el análisis de la matriz de confusión revela la dificultad del modelo para identificar la clase minoritaria ("Desocupados"): de 13 individuos efectivamente desocupados en el set de prueba, el modelo no logró clasificar correctamente a ninguno (0 Verdaderos Positivos), volcando la predicción hacia la clase mayoritaria.

B. Análisis Discriminante Lineal (LDA)

El método LDA mostró un desempeño sobresaliente en términos de exactitud global, alcanzando un **100% (1.00)** tanto para la muestra de 2005 como para la de 2025. Este resultado sugiere que, bajo los supuestos de normalidad y homocedasticidad de las covariables, el hiperplano discriminante logra segregar eficazmente las categorías en el espacio de características reducido.

C. K-Vecinos Más Cercanos (**k**-NN), con k=3

Se evaluó el desempeño del algoritmo para un rango de vecinos $k \in [1, 9]$. Para el reporte final, se seleccionó **k=3** siguiendo la consigna. Para 2005, se obtuvo una exactitud de **0.940**, mientras que para 2025, se registró una exactitud de **0.969**. El método no paramétrico demostró ser robusto, manteniendo niveles de precisión comparables a los métodos lineales en el periodo más reciente.

D. Naive Bayes

El clasificador Naive Bayes presentó el desempeño más bajo del conjunto. En el caso de 2005, la exactitud es de **0.752**, mientras que para el caso de 2025, la exactitud es de **0.555**. Este deterioro significativo, particularmente en 2025, sugiere que la fuerte asunción de independencia condicional entre los predictores no se sostiene en la estructura de datos de la EPH, donde existe una alta correlación entre las características socioeconómicas y laborales.

3. Comparen los resultados de 2005 versus 2025. ¿Cuál de los métodos predice mejor en cada año? Justifiquen detalladamente utilizando las medidas de precisión que conocen.

Respuesta:

A partir de las métricas obtenidas (Matriz de Confusión, Curva ROC, AUC y *Accuracy*), se observa un patrón claro de superioridad de los modelos lineales sobre los probabilísticos y no paramétricos en ambos periodos. A continuación, se detalla la selección del mejor predictor para cada año.

Modelo	**Accuracy 2005**	**Accuracy 2025**
Análisis Discriminante Lineal (LDA)	1.000	1.000
Regresión Logística	0.997	0.969
K-Vecinos Cercanos (**k**=3)	0.940	0.971
Naive Bayes	0.752	0.555

Lo de LDA es definitivamente muy raro, probablemente se deba a overfitting, dado que se eliminar los valores nulos y la gran cantidad de columnas LDA no es confiable.

Para el año 2005, LDA alcanzó una exactitud del 100%, mientras que la Regresión Logística obtuvo un AUC de 1.00 y una exactitud del 99.7%. La matriz de confusión de la logística muestra errores mínimos (solo 1 falso negativo). Esto sugiere que, dada la estructura de las variables explicativas seleccionadas tras la limpieza, las clases "Desocupado" y "No

Desocupado" son linealmente separables en el hiperplano de características de 2005. Naive Bayes, por el contrario, tuvo un desempeño deficiente (0.75), indicando que la interdependencia entre predictores castiga severamente su capacidad predictiva.

Para el año 2025, si bien la Regresión Logística muestra una *accuracy* alta (0.969), esta métrica es engañosa debido al desbalance de clases (solo 3.69% de desocupados). Al observar su matriz de confusión, el modelo falló en detectar la totalidad de los casos positivos (0 verdaderos positivos), comportándose como un clasificador trivial que asigna a todos la clase mayoritaria. Su AUC cayó a **0.71**, reflejando esta pérdida de poder predictivo. En contraste, el reporte de *accuracy* perfecta del LDA sugiere que este método logró mantener la separabilidad de las clases que la logística perdió, consolidándose como el modelo más robusto entre los evaluados.

Si tomamos estos números para concluir, el método que predice mejor en ambos años es el Análisis Discriminante Lineal (LDA), significa que acertó todos los desocupados. Eso es matemáticamente sospechoso (probablemente *overfitting* o *data leakage*).

4. Con el método que seleccionaron, predigan qué personas son desocupadas dentro de la base no respondieron. ¿Qué proporción de las personas que no respondieron pudieron identificar como desocupadas?

Respuesta:

Dado que en la base de Bahía Blanca todos respondieron la encuesta, es decir no había datos con ESTADO=0, no se pudo realizar este inciso.

Referencias

Instituto Nacional de Estadística y Censos. (2011). *Encuesta Permanente de Hogares (EPH): Conceptos de condición de actividad, subocupación horaria y categoría ocupacional* [PDF]. Gobierno de Argentina.
https://www.indec.gob.ar/ftp/cuadros/menusuperior/eph/EPH_Conceptos.pdf