Clasificación y regularización de desocupación usando la EPH

Trabajo Práctico 4

F. Agustín Acosta*

Luca F. Armelini Salvaj**

Gorki S. Freire Zambrano***

Maestría en Economía - Big Data

Profesor: Walter Sosa Escudero

Tutora: Pilar Hüppi Lo Prete

6 de febrero de 2026

Link al repositorio.

Último Commit & Push: "Entrega Final del TP".

Aglomerado (Grupo 6): Bahía Blanca - Cerri (Código 03).

*facosta@udesa.edu.ar.

**larmelinisalvaj@udesa.edu.ar

***greirezambrano@udesa.edu.ar

P I: Análisis de la base de hogares y tipo de ocupación

Exploración y Tratamiento de la base de datos

A partir de un análisis preliminar exploratorio del registro de la base de hogar, se consideran algunas variables en particular como potencialmente relevantes para predecir desocupación. Entre ellas, *NIVEL_ED* indica acumulación de capital humano y calificación, con lo que probablemente se relacione a menores chances de estar desocupado; lo mismo sería esperable a medida que la persona es mayor en edad (*CH06*). Otras como *II2/II6* establecen si el hogar cuenta con un (o más de un) espacio de trabajo, lo que podría indicar que las personas de ese hogar son menos propensas a estar desocupadas; *II7* establece qué situación de propiedad del espacio físico tiene el hogar, lo que puede relacionarse con la desocupación u ocupación según el caso; *V2* evalúa si el hogar cuenta con una jubilación o pensión como medio de ingreso; *V3 y V4* si el hogar se sostiene gracias a indemnización por despido o seguro de desempleo; *V5-V19* recopilan distintos medios adicionales a lo laboral por los que un hogar se sostuvo los últimos tres meses. Todas estas estrategias de sostén del hogar podrían estar asociadas a desocupación positiva o negativamente, según el caso. Luego, se consideran potencialmente relevantes *IPCF*, que indica el ingreso per cápita familiar, y *VII* que indica la organización del hogar. Ambos útiles para detectar asociaciones a ocupación/desocupación según los niveles de ingreso y cómo se aborden las tareas del hogar.

En una segunda instancia, se descarga de la base de microdatos de la EPH correspondiente al primer trimestre de 2005 y 2025 en los formatos indicados en el enunciado 1.2.[1] Seguidamente, se procede al tratamiento de los datos, con la limpieza y construcción de la base de datos final a utilizar en el ejercicio de predicción. Primero, se filtra por la región "Bahía Blanca - Cerri", asignada a nuestro grupo (Grupo 6). Luego, se realiza un concatenación entre la base de hogares y la de personas o individuos. Una vez que esto ha sido realizado, se procede a realizar un `merge` entre la base de 2005 y la de 2025 usando las variables *CODUSU* y *NRO_Hogar*.

No se realiza, como parte del trabajo de limpieza ex-ante de la base, eliminación alguna de los datos NaN (vacíos). Esto se debe a que, con ellos, se eliminarían filas (observaciones) potencialmente relevantes para el análisis más adelante, en columnas (variables) que difieren entre bases pero que pueden ser útiles.[2] Por ende, de eliminarlas, se estaría incurriendo en un riesgo de perder información útil para el análisis en las otras dimensiones en las que sí se cuenta con datos válidos para esas observaciones. En el mismo sentido, tampoco se eliminan variables que consideremos "irrelevantes" para el análisis, como una conducta precautoria ante la eventualidad de que puedan resultar útiles más adelante.

[1] Ambas están subidas al repositorio de Github, en la subcarpeta "Datasets" de la carpeta "TP4".

[2] Este es el caso de la variable V5, que utilizamos para generar una de las tres nuevas variables en respuesta al enunciado 1.4.

Se continúa convirtiendo los valores de algunas columnas que deberían ser numéricos pero pueden encontrarse cargados con formato de texto (objeto/string). Para ello, seleccionamos una serie de variables susceptibles a este inconveniente y hacemos la conversión, donde lo que no sea número se vuelve un dato vacío. Posteriormente, se opta por reemplazar los valores negativos en columnas (variables) numéricas de la base por NaN, lo cual se justifica en el sinsentido económico de estos valores para cualquier variable numérica incluida en la EPH preservando la integridad de la muestra (sin eliminar las filas) al simplemente marcar el dato específico como faltante.

En la EPH existen variables categóricas dicotómicas cuyas categorías 'Sí' y 'No' equivalen a 1 y 2 respectivamente, las cuales contienen algunos datos figura la categoría textual y en otros la numérica. Por ello, armonizamos el conjunto de datos poniendo los valores de estas columnas en su definición numérica, útil para su utilización más adelante. Para evitar que los números resultantes queden formateados como texto, se realiza una conversión ex-post a la armonización de todo lo que quedó como texto a número, donde lo que no es posible convertir a número queda como NaN (los NaN previos, si los hubiera).

Una vez hecho este trabajo, se procede con la armonización de dos variables relevantes para el análisis posterior: *NIVEL_ED* y *ESTADO*, que indican el nivel educativo de la persona y su estado laboral, respectivamente. Esto se realiza con el motivo de amalgamar los formatos con que ambas bases tratan los valores para estas columnas, poniendo el conjunto de datos en sus términos numéricos, de modo que el código pueda interpretarlos correctamente.[3] Adicionalmente, se modifican los valores 7 y 9 de *NIVEL_ED*, dado que esta variable toma valores de 1 a 6 en nivel educativo de manera incremental (de primaria incompleta a superior universitaria completa), mientras que el nivel 7 indica 'Sin instrucción' y el 9 indica los casos "No sabe/No responde" ('Ns/Nr'). Por lo tanto, manteniendo la lógica incremental, reasignamos el valor 0 a la categoría 'Sin instrucción' y hacemos explícita la ausencia del dato convirtiendo los casos 'Ns/Nr' a NaN, evitando así también que afecten el cálculo de la nueva variable que se genera más adelante.

Por último, se proponen y construyen tres variables adicionales que, a nuestro juicio, serían útiles para predecir si un individuo se encuentra desocupado. La primera es la *máxima educación en el hogar (max_ed_h)*, que indica el nivel educativo más alto alcanzado por algún miembro del hogar. Da idea del clima educativo del hogar y captura el "techo" de capital humano y de potencial "efecto par" (efecto impulso a los demás miembros), que puede influir en la probabilidad de desocupación. Para la generación de esta variable, se agrupan los individuos según *CODUSU* y *NRO_HOGAR* y se busca el máximo valor de *NIVEL_ED*, previamente trabajada. Para mostrar la distribución, por año, de

[3] Por ejemplo, la primera categoría de *NIVEL_ED* indica individuos que no completaron el nivel primario de educación, casos que en la base 2025 figuran como "1", mientras que en la base 2005 lo hacen como "Primaria Incompleta (incluye educación especial)". Lo análogo sucede para *ESTADO* cuya primera categoría indica 'Ocupado' y figura tanto de esa manera como con el código 1.

las observaciones según esta nueva variable, se presenta el siguiente histograma.[4]

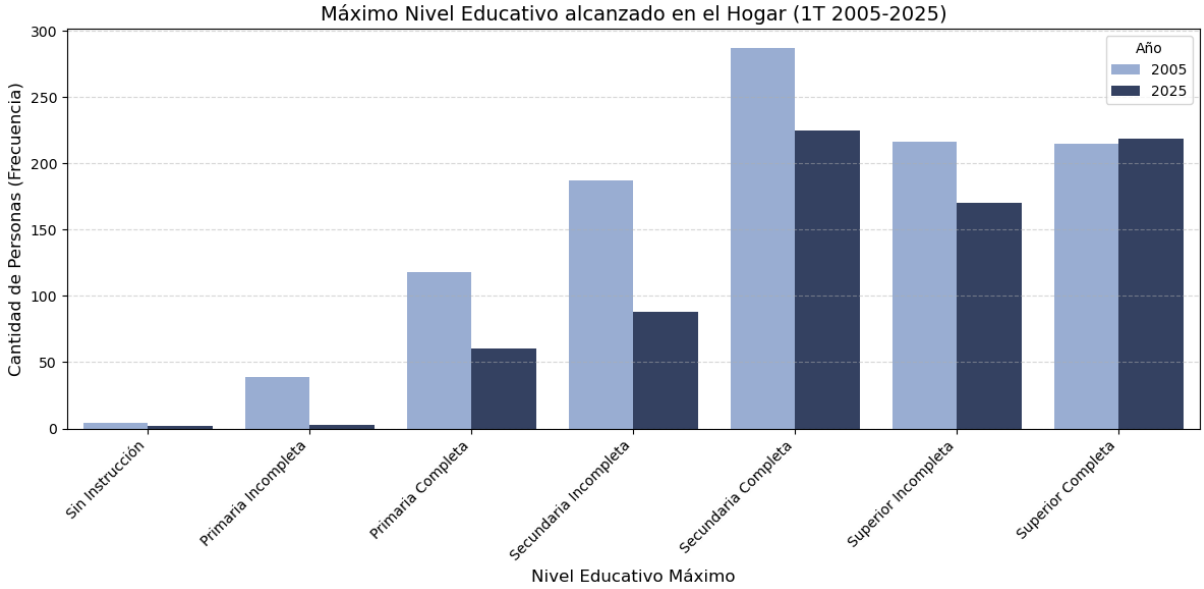

La segunda variable generada por nuestra cuenta es definida como *tasa de "dependencia" (tdep)*, que mide la relación entre miembros que denominamos "dependientes" (menores de 14 años y mayores de 65 años) y miembros en edad activa (14 a 65 años) del hogar. Esta variable podría ser un predictor importante de desocupación en cuanto a que da idea del requerimiento de tiempo (por cuidado, etc.) de una persona a quedare en su hogar, especialmente en caso de mujeres. Se calcula esta tasa como

$$tdep = \frac{\text{Cantidad de Dependientes (niños + ancianos)}}{\text{Cantidad de Activos (14 a 65 años)}}.$$

En los casos donde el denominador es 0 (ningún miembro del hogar está en edad activa), matemáticamente, la tasa de dependencia tendería a infinito. Para abordar este problema lo "menos arbitrariamente" posible, representamos el extremo de dependencia reemplazando el infinito por un límite superior, calculado con el valor máximo (finito) de la tasa en la muestra sumado a un escalar δ definido como el valor mínimo positivo de la tasa en la muestra.[5] A continuación se presentan estadísticas descriptivas básicas de la variable.

[4] También cargado al repositorio de GitHub, en la subcarpeta "Plots" de la carpeta "TP4".

[5] Con este criterio, se mantiene el orden relativo de los hogares (ranking) poniendo a los de "infinita" dependencia en la cima utilizando una brecha "data-driven" con el "salto mínimo" de dependencia observado en la muestra.

Tabla 1: Comparativa de la distribución de la Tasa de Dependencia por año.

Año	**Conteo**	**Media**	**Desvío Estándar**	**Mín**	**25 %**	**50 %**	**75 %**	**Máx**
2005	1066	1.037	1.836	0.0	0.0	0.333	1.0	6.167
2025	767	1.118	1.892	0.0	0.0	0.500	1.0	6.167

Nota: El valor máximo incluye la imputación para hogares sin población activa ($\delta = 0{,}167$).

Las estadísticas indican un aumento en la carga de dependencia de los hogares entre 2005 y 2025. a tasa de dependencia promedio aumentó de 1.037 a 1.118, lo que implica una mayor carga de inactivos (menores y adultos mayores) sobre la población en edad laboral. Esto se ve principalmente en el hogar representativo (mediana), donde la tasa saltó de 0.333 (aprox. 1 dependiente cada 3 activos) en 2005 a 0.500 (1 dependiente cada 2 activos) en 2025. Este incremento, acompañado por un ligero aumento en la dispersión (desvío de 1.836 a 1.892), sugiere una mayor presión sobre los generadores de ingresos.

La tercera variable captura un *hogar mantenido con un ingreso no laboral "adicional" (ADICIONAL)*. Consta de una dummy para hogares cuyos miembros se mantuvieron durante los últimos tres meses gracias a un ingreso no asociado a lo laboral (subsidio, ayudas, etc.), descartando pensiones, ahorro/interés, y renta. Se considera a esta variable un potencial predictor relevante de desocupación al reducir la necesidad de ingresos laborales, desalentanddo la búsqueda activa de empleo. Para su construcción utilizamos las siguientes variables de la sección *Estrategias del Hogar* de la EPH: *V5* (Subsidio), *V6-V7* (Ayuda en especies), *V12* (Ayudas monetarias), *V14* (Préstamos de familiares/amigos), *V17* (Venta pertenencias), *V18* (Limosnas, juegos de azar, etc.), *V19_A* (Trabajo niño), y *V19_B* (Mendicidad niño). Se excluyen el resto de variables de la sección en la consideración para el cálculo de *ADICIONAL* por estar vinculadas a una situación laboral o de tenencia de activos en particular. Para la correcta computación de *ADICIONAL*, es necesaria una previa una armonización de *V5* entre bases 2005 y 2025. Hacemos esto colapsando la desagregación presente en la base 2025 de los 3 subsidios particulares a una sola variable, como en la base 2005. Esta transformación asigna un 'Sí' (1) en caso de una respuesta afirmativa a alguna de las tres asignaciones específicas, un 'No' (0) en caso de ausencia de respuesta afirmativa de recibir cualquier asignación y al menos una respuesta negativa, y dejamos vacío (NaN) en caso de no exista dato de respuesta alguno a cualquier asignación o en la pregunta general en la base 2005. Se detecta el caso afirmativo buscando el máximo entre las subcategorías, donde se computa si es igual a 1, es decir, si al menos hay una respuesta afirmativa. Para no sobrescribir esos NaNs en la transformación, los rellenamos temporalmente con -1 como "placeholder" y lo restauramos a NaN luego de la conversión. A continuación, se muestra el porcentaje de hogares encuestados que, durante tres meses, se sostuvieron gracias a un ingreso no laboral adicional.

Tabla 2: Comparativa de encuestados con ingresos adicionales no laborales.

Año	Conteo	Sostén con Ingreso Adicional	Sostén con Otro Ingreso
2005	1066	335 (31,4 %)	731 (69,6 %)
2025	767	216 (28,2 %)	551(72,8 %)

Estadísticas Descriptivas y Tasa de Desocupación

La primera es la presentada justo arriba, el porcentaje de hogares que se sostuvieron durante los últimos tres meses previos a ser encuestados, gracias a un ingreso "adicional", es decir, no asociado a lo laboral (*ADICIONAL*). Dado que esta variable se compone de otras presentes solo en la encuesta de hogares, se presentan sus estadísticas descriptivas como parte de las solicitadas en el enunciado 1.5 de este trabajo .

Para la segunda, se selecciona la distribución de Ingreso per cápita familiar (*IPCF*) para 2005 y 2025. Tiene sentido pensar que aquellos con menores ingresos es más probable que se encuentren desocupados.

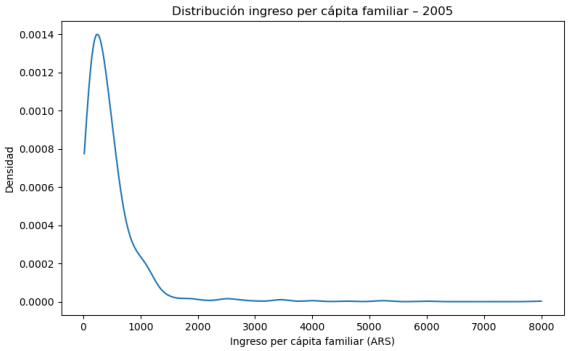

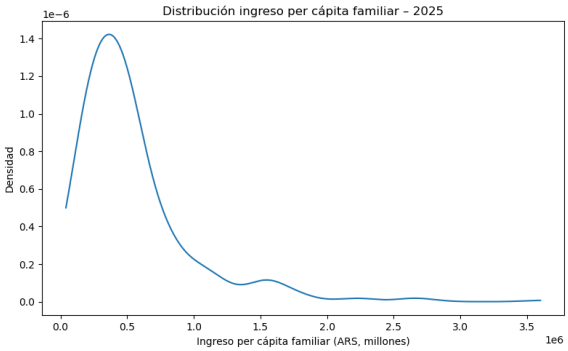

Como tercera y cuarta estadística descriptiva relevante, se presenta la distribución de miembros por hogar (*IX_ TOT*) y la distribución de menores a 10 años por hogar (*IX_ MEN10*), potencialmente influyentes en las presiones económicas en un hogar.

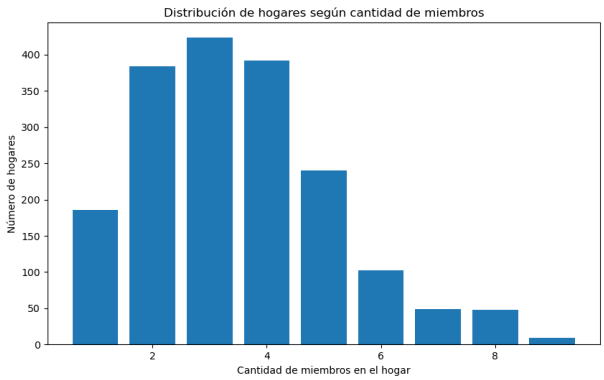

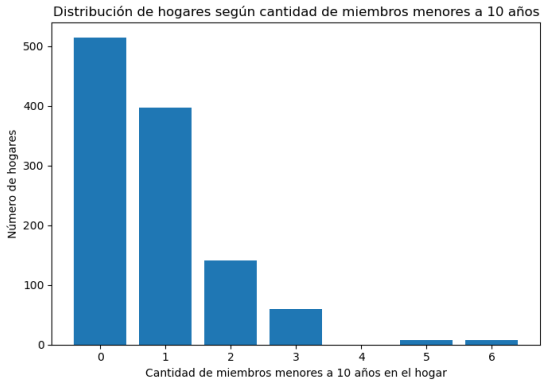

Para la quinta estadística, se decide presentar el tipo de piso interior del hogar (*IV3*), entendiéndolo como un posible proxy de pobreza y desempleo.

Tabla 3: Tipo de Piso por Hogar.

Conteo	**Mosaico/Baldosa**	**Cemento/Ladrillo Fijo**
1818	1710 (94,1 %)	108 (5,9 %)

En cuanto al cómputo de la tasa de hogares con desocupación, a diferencia de la tasa clásica (que cuenta personas), esta mide la vulnerabilidad del núcleo familiar. Para su construcción, siguiendo la consigna de utilizar una sola observación por hogar, se adoptó un criterio de incidencia: se considera 'Hogar con Desocupación' a toda unidad doméstica económicamente activa que cuente con, al menos, un integrante desocupado, y se define "Hogar Activo" como aquel que tiene al menos un miembro activo (Ocupado o Desocupado). Esta decisión se fundamenta en la teoría del hogar como unidad de maximización conjunta de utilidad y mutualización de recursos. Dado que los ingresos laborales suelen funcionar como un fondo común, la desocupación de un miembro, independientemente de su posición (jefe, cónyuge o hijo), representa un shock de ingreso negativo que impacta en el bienestar y consumo de todo el grupo familiar. Por tanto, este indicador complementa a la tasa individual del INDEC, permitiendo revelar el alcance social de la problemática laboral y la vulnerabilidad de la estructura de ingresos de los hogares. Dada esta definición, formalmente, la tasa de hogares con desocupación se calculó como:

$$tdep = \frac{\text{Hogares con Desocupación}}{\text{Hogares Activos}} \times 100.$$

El informe del INDEC para el 1er Trimestre de 2025 presenta la estadística de la tasa de desocupación para el total de aglomerados en un 7.9 %; mientras que, para el aglomerado de Bahía Blanca - Cerri, se reporta una tasa de 4.8 %. El cómputo para la tasa de hogares con desocupación calculada para este trabajo, resulta en 14.73 % para el aglomerado de Bahía Blanca - Cerri para el 1er trimestre de 2005 y en 7.99 % para el 1er trimestre de 2025. Este último dato es significativamente más alto (casi el doble) del reportado por el INDEC para la tasa de desocupación a nivel individuos. Este resultado es esperable. Al ser una variable binaria a nivel hogar (basta un 1 para que sea positivo), la probabilidad de que un hogar clasifique como desocupado aumenta con el tamaño del hogar. No es que el dato esté "inflado", sino que refleja que el desempleo está disperso entre las familias y no concentrado solo en individuos aislados. Se advierte que no se encuentran disponibles los informes del INDEC para el mercado de trabajo anteriores a 2016, por lo que se limita la comparación únicamente al 1er trimestre de 2025.

P II: Clasificación y regularización

Partición de la base y elección de λ por CV

Para esta segunda parte, se comienza recuperando la base final obtenida de la parte anterior, la cual nombramos "*Base_predic.xlsx*". Posteriormente, se revisa el filtro que da lugar a la sub-muestra *'respondieron'*, para lo cual se observa que en la base traída de la parte anterior no se encuentran observaciones que no hayan reportado su estado laboral en la encuesta. Para comprobar que no se trata de un error o périda de información previa, se revisan estos casos en las bases individuales originales y en la 'mergeada'. Se comprueba presencia de no-respuestas en las bases originales individuales, pero ausencia de dichos casos en la base mergeada. De hecho, se elimina la posibilidad de que esto ocurra como fallo colateral del merge, comprobando que, una vez se filtra por el aglomerado de trabajo (Bahía Blanca - Cerri), no quedan observaciones de este tipo en las encuestas individuales por separado. Por tanto, la base de datos "*Base_predic.xlsx*", ya es una base de solo casos con respuesta para la variable $ESTADO$, y entonces se procede a trabajar con ella.

Seguidamente, se realiza una limpieza antes de la etapa de división de la muestra para modelado, que consiste en dejar de lado las observaciones donde $ESTADO = 0$ que indica 'Menor de 10 años', ya que no forman parte de la PEA y por ende no son relevantes para el ejercicio de predicción de desocupación. En la definición de la matriz X, hacemos una limpieza para el modelo predictivo. Primero, unificamos las columnas que quedaron diferenciadas por repetirse en el merge. Segundo, sacamos variables que distinguen, por definición, a individuos ocupados y desocupados, y otras que entre sí generan fuerte multicolinealidad, manteniendo solo una de ellas (por ejemplo, mantenemos el monto de ingreso y dejamos de lado los deciles). Tercero, nos quedamos únicamente con las numéricas sin considerar ponderadores o variables indicadoras irrelevantes de la encuesta. Una vez hecho esto, se procede con metodología de *'split'* en una submuestra de entrenamiento (*'train'*) y otra de prueba (*'test'*), siguiendo las indicaciones en el enunciado 2.1 del TP (más detalle en el código).

La elección de λ por validación cruzada (CV por sus siglas en inglés: *'cross validation'*), consiste en elegir el hiperparámetro de penalización (λ) pasando por un proceso que puede sintetizarse en cuatro etapas. La primera, la de división interna, se sigue de la división de la muestra que se realizó previamente. Se toma únicamente el conjunto de entrenamiento (X_train) y se lo divide en k pliegues o *'folds'*. La segunda etapa consiste en una iteración de valores para λ. Esto es, se define una grilla de posibles valores para λ y se itera sobre ellos. Posteriormente, en la tercera etapa, se define esa iteración en términos de entrenamiento y validación. Para cada valor candidato de λ, se entrena el modelo en $K - 1$ pliegues, se evalúa el error en el pliegue restante (que funciona como un "mini test"), y se repite este proceso k veces rotando el pliegue de evaluación. De ahí el nombre de *validación cruzada*. La cuarta etapa consiste la selección del hiperparámetro,

la cual parte del cálculo del error promedio de los k pliegues para ese λ y se selecciona como "ganador" a aquel que minimiza ese error promedio de validación. Una vez elegido, se re-entrena el modelo con ese λ óptimo usando toda la base de entrenamiento (X_train).

No se utiliza el conjunto de prueba (X_test) para la elección de λ por el simple hecho de que, entonces, no se estaría validando realmente el valor del hiperparámetro. Es decir, si se utiliza el conjunto de test para elegir el mejor λ, estamos "ajustando" el modelo a esos datos específicos. El test deja de ser un evaluador imparcial y se convierte en parte del entrenamiento. En ese caso, el error que se reportaría sería falsamente bajo (demasiado bueno), porque se estaría eligiendo el parámetro que mejor funcionaba para esos datos específicos, y no necesariamente el que mejor generaliza al mundo real.

En validación cruzada, las implicancias de tener un k muy chico o grande tienen que ver con el *trade-off* sesgo-varianza (y poder computacional). Utilizar un k (cantidad de pliegues) muy pequeño, implica mayor sesgo pero menor varianza y costo computacional. Al dividir la muestra en pocos grupos, el conjunto de entrenamiento de cada iteración es considerablemente más pequeño que la base original (por ejemplo, con $k = 2$ se entrena solo con el 50 % de los datos). Si el modelo mejora mucho al tener más datos, usar un k bajo sobreestimará el error del modelo final (será pesimista), generando un sesgo alto. Sin embargo, como se entrenan pocos modelos, el costo computacional es bajo; y como los conjuntos de entrenamiento de cada pliegue se superponen poco (son muy distintos entre sí), las estimaciones de error suelen ser menos correlacionadas (menor varianza).

Por otro lado, utilizar un k muy grande, deriva en un menor sesgo pero a costa de mayor varianza y costo computacional. En este caso, el conjunto de entrenamiento en cada iteración es casi del tamaño de la base original (con $k = 10$ se usa el 90 %). Esto hace que la estimación del error sea muy precisa y cercana a la performance real del modelo final. Sin embargo, como los conjuntos de entrenamiento son muy similares entre iteraciones (comparten gran parte de las observaciones), los modelos entrenados estarán altamente correlacionados. El promedio de muchas variables altamente correlacionadas tiene una varianza mayor que el promedio de variables independientes. Y, como se debe entrenar y evaluar el modelo muchas veces, el costo computacional es también mayor.

En el caso extremo de $k = n$ (número de muestras o total de observaciones), el método se vuelve un *Leave-One-Out Cross-Validation* (LOOCV). En cada iteración, se separa una sola observación para testear y se entrena con todas las demás ($n-1$). Esto se repite para cada dato de la base, por lo que el modelo se estima n veces. Dado que se entrena con casi la totalidad de los datos, el estimador resultante es el que tiene el menor sesgo posible pero con varianza máxima, y es extremadamente costoso computacionalmente especialmente cuando la base es grande (como en el caso de la EPH).

Regresión Logísitica con LASSO y Ridge, y elección del λ óptimo

Abordamos la naturaleza binaria de la variable dependiente, siguiendo la consigna, implementando dos métodos de regresión logística: *LASSO* y Ridge. Primero, se realizó una imputación y estandarización. Dada la presencia de datos vacíos luego de eliminar aquellas columnas puramente vacías, se imputa esos valores utilizando la mediana (buscando robustez ante posibles outliers); y, posteriormente, se estandarizaron todos los predictores, dado que los métodos de regularización son sensibles a la escala de las variables. En segundo lugar, se procedió con la elección óptima del hiperparámetro de penalidad mediante validación cruzada de 5 pliegues, donde el λ óptimo es aquel que maximizó el área bajo la curva ROC (AUC). Se prefiere esta métrica por sobre la exactitud (Accuracy) dado el desbalance de clases observado en la muestra (baja proporción de desocupados). Se utilizó el algoritmo de optimización (*solver*) *'saga'*, adecuado para problemas grandes y capaz de manejar ambas penalidades (L1 y L2) eficientemente. A continuación, se reportan las métricas de desempeño en el conjunto de prueba (test set), las matrices de confusión y la curva ROC, para los modelos optimizados y para cada año analizado.

Tabla 4: Desempeño de los Modelos Lasso y Ridge por año

Panel A: Métricas de Desempeño				
	Año 2005		**Año 2025**	
Métrica	Lasso	Ridge	Lasso	Ridge
λ óptimo	11.288	0.089	1.6238	10000
Accuracy	0.926	0.919	0.9610	0.9610
AUC	0.740	0.716	0.6992	0.5470
Panel B: Matrices de Confusión				
	Año 2005		**Año 2025**	
Lasso	Pred (0)	Pred (1)	Pred (0)	Pred (1)
Real 0	263	0	197	0
Real 1	21	0	8	0
Ridge	Pred (0)	Pred (1)	Pred (0)	Pred (1)
Real 0	261	2	197	0
Real 1	21	0	8	0

Nota: Las columnas originales son 60, y después de limpieza de vacíos quedan en 49 para 2005, y en 56 para 2025.

Al comparar estos resultados con los obtenidos mediante regresión logística estándar (sin penalización) en el TP3, observamos que el desempeño o ajuste de los modelos mejora. La regularización, especialmente Lasso, permitió simplificar el modelo al anular coeficientes de variables ruidosas, lo cual es consistente con la mejora observada en el AUC. Para el año 2005, ambos modelos se desempeñaron razonablemente (AUC por encima de 0.7),

aunque el rendimiento de Ridge fue inferior que el de Lasso. Si bien las Accuracy son altas, las matrices de confusión revelan modelos conservadores, clasificando a la mayoría de las observaciones en la clase mayoritaria (ocupados). Esto ilustra por qué la Accuracy no es una métrica adecuada para problemas desbalanceados como el desempleo. En el año 2025, la diferencia real entre modelos se observa en el AUC. Lasso (AUC 0.699) asigna probabilidades más altas de desempleo a los verdaderos desocupados, aunque no superen el umbral de corte del 50 % para la clasificación dura; mientras que Ridge (AUC 0.547) falló en capturar cualquier señal, comportándose casi como una predicción al azar. Lo mismo se aprecia en las curvas ROC presentadas abajo. La curva ROC de Lasso (línea azul) se mantiene por encima de la de Ridge (línea naranja) en la mayor parte del espectro, confirmando su superioridad en la capacidad de ranking para ambos períodos. Se observa también que la curva de Ridge para 2025 cae hacia la diagonal (desempeño aleatorio), mientras que Lasso logra mantener convexidad indicando mayor poder predictivo real.

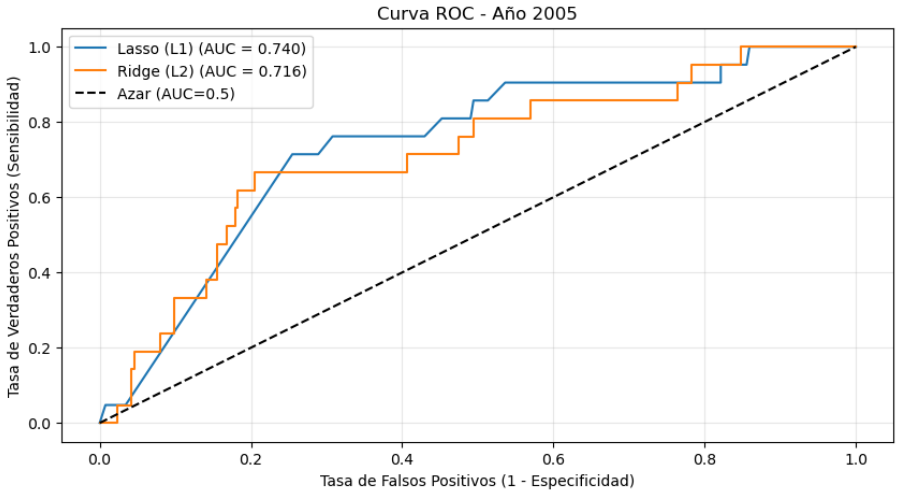

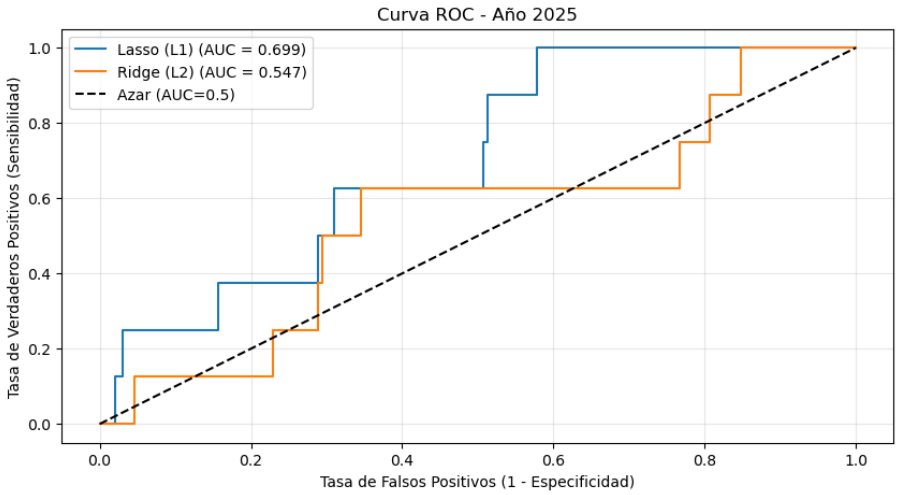

Para determinar el nivel óptimo de penalización en los modelos de regresión logística regularizada (Lasso y Ridge), se seleccionó el hiperparámetro por una validación cruzada

de 10 pliegues (10-fold Cross-Validation). Se exploró un rango de valores para λ, definido como $\lambda = 10^n$ con $n \in \{-5, -4, \ldots, 4, 5\}$, como se indica en consigna. Dado el fuerte desbalance de clases observado (especialmente en 2025), se utilizó el Área Bajo la Curva ROC (AUC) como métrica de evaluación para seleccionar el λ óptimo, obligando al algoritmo a buscar configuraciones que realmente discriminen la probabilidad de desempleo.

Para el año 2005, la figura de caja muestra cómo varía el error (representado como $1 - \text{AUC}$) en función del log de λ. Lasso (cajas azules) mantiene un error estable y bajo en valores intermedios de penalización, mientras que Ridge (cajas verdes) se degrada rápidamente cuando la penalización aumenta excesivamente. El gráfico de línea debajo, confirma el comportamiento teórico de Lasso: a medida que aumenta la penalización (λ), la proporción de coeficientes anulados crece siguiendo una curva con "forma de S".

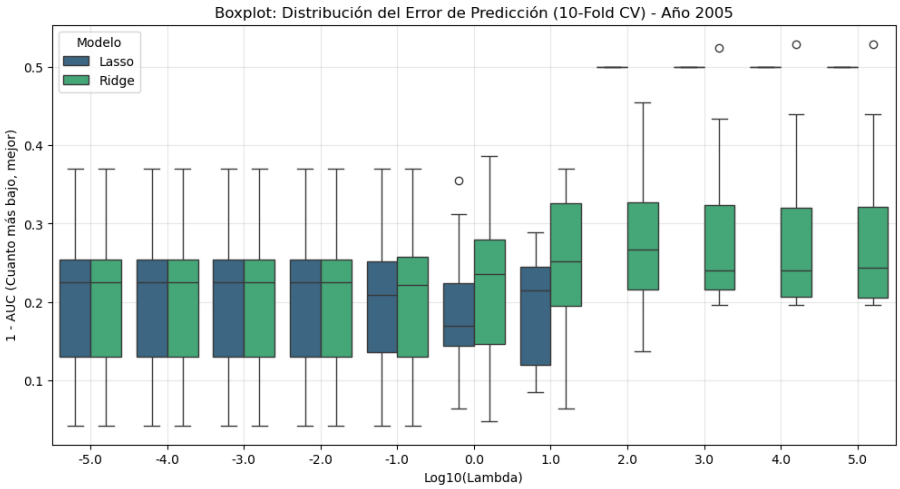

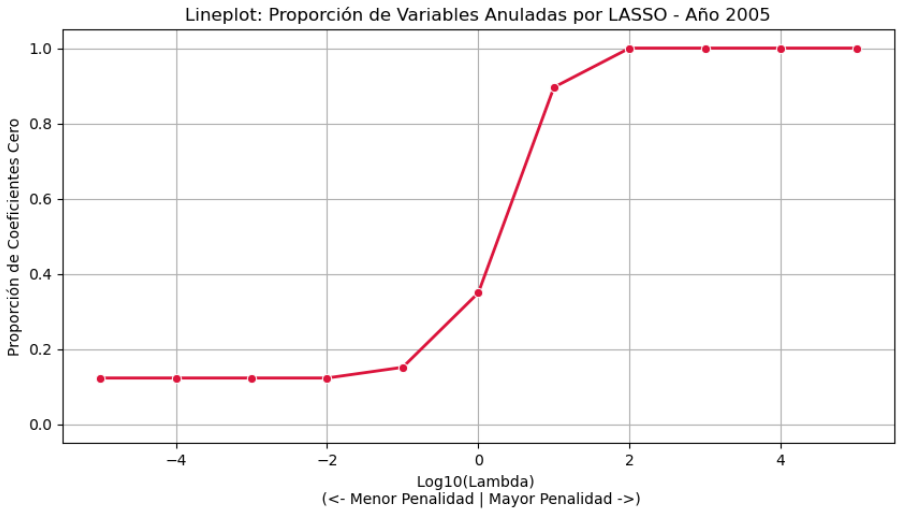

En 2025, el modelo enfrentó un desafío mayor con 56 variables y una clase minoritaria de desocupados. Ambos métodos (Lasso y Ridge) seleccionaron el λ mínimo del rango (10^{-5}). Sin embargo, el resultado de AUC Medio: NaN en la consola indica que, en algunos folds de la validación cruzada, es probable que no hubiera suficientes casos positivos

(desocupados) en el conjunto de validación para calcular el AUC, o que el modelo colapsara prediciendo probabilidades constantes. Los gráficos boxplot del error de predicción de ambos modelos y lineplot de las variables anuladas por Lasso para 2025 son los siguientes.

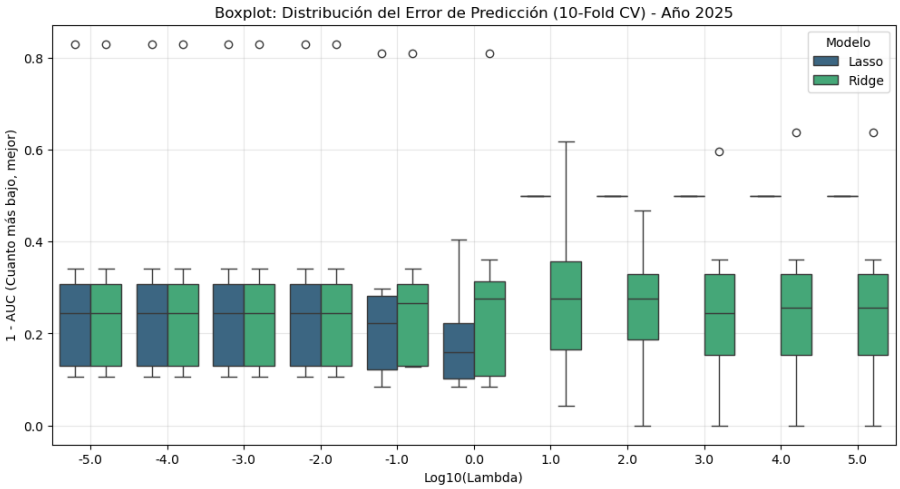

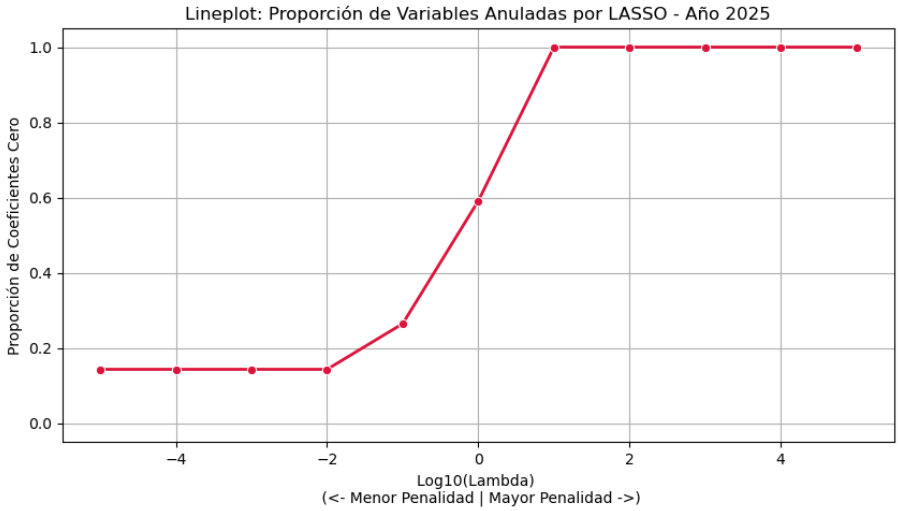

Recordemos que la propiedad principal de LASSO es su capacidad de "anular" coeficientes (llevarlos a cero), descartando así las variables que no aportan información relevante para la predicción. Analizando los coeficientes del LASSO estimado con el λ óptimo, se observa que para el año 2005 el modelo es bastante parsimonioso, consecuencia de una penalización alta seleccionada por el modelo ($\lambda = 10$). El modelo eliminó la gran mayoría de las variables, incluyendo algunas estructurales como *NIVEL_ED* (Nivel Educativo), *CH06* (Edad), *IPCF* (Ingreso Per Cápita Familiar) y variables de vivienda (*IV2*, *IV3*). Las únicas sobrevivientes fueron *P47T* (Monto de ingreso personal), *edad_activa* y *V6* (ayuda social/gubernamental). Se esperaba que variables de capital humano como *NIVEL_ED* fueran determinantes. Sin embargo, LASSO detectó que, con una penalización fuerte, *P47T* e *edad_activa* eran suficientes para predecir, descartando la educación por redundancia o menor poder predictivo marginal. Sin embargo, el peso negativo de *P47T*

es lógico puesto que a mayor ingreso personal, menor probabilidad de estar desocupado. Lo inverso con *V6*, variable que forma parte de *ADICIONAL*, construida a nivel hogar.

Para el año 2025, el λ óptimo fue muy cercano a cero, comportándose casi como una regresión logística estándar sin penalización. Solo se eliminaron variables con poca varianza (por ej. *V10*, *intercepto*), conservando el 85 % de los predictores con variables clave como *NIVEL_ED* (1.5143), *CH06* (-1.6885) y *P47T* (-1.2389). El resultado es ahora acorde a lo esperado. Las variables con mayores coeficientes (en valor absoluto) son la Edad (*CH06*) y el Nivel Educativo (*NIVEL_ED*). El modelo de este último año, 2025, valida la hipótesis planteada en la Parte I, asignando los coeficientes más altos precisamente a *NIVEL_ED*, *CH06* y *V6*. El modelo de 2005, aunque descarta estas variables explícitas, mantiene *edad_activa* (relacionada con la edad) y *P47T* (que suele estar correlacionada con la educación). Esto sugiere que la hipótesis teórica sigue siendo válida, aunque el instrumento matemático (LASSO con $\lambda = 10$) pareciera haber priorizado la síntesis sobre la explicabilidad más directa. Este contraste entre años muestra cómo la regularización puede cambiar la "historia" que cuenta el modelo (pasando de uno parsimonioso en 2005 a uno más detallado en 2025), dependiendo de la señal que encuentre en los datos.

Se concluye el análisis evaluando la calidad de las predicciones probabilísticas utilizando el Error Cuadrático Medio (ECM), el cual penaliza la distancia entre la probabilidad estimada y el valor real de la clase (0 o 1).

Tabla 5: Comparación de Hiperparámetros y Error Cuadrático Medio - 2005 vs 2025

	Año 2005		**Año 2025**	
Métrica	**Lasso**	**Ridge**	**Lasso**	**Ridge**
Lambda (λ)	11.288	0.089	1.6238	10000
ECM	0.0682	0.0693	0.0380	0.0379

Considerando la totalidad de la evidencia (AUC, Matriz de Confusión y ECM), se concluye que la regularización LASSO funcionó mejor. En 2005, fue superior con menor ECM, mayor AUC (0.740) y una mayor simplificación del modelo al eliminar variables redundantes. En 2025, aunque Ridge obtuvo un ECM infinitesimalmente menor, lo logró mediante un modelo "nulo" ($\lambda = 10000$) que anuló toda capacidad predictiva (AUC $\approx$ 0.54). Lasso, con un ECM prácticamente igual, logró mantener un AUC de ≈ 0.70, mostrando que sí intentó aprender patrones en lugar de apostar por el promedio. Por todo esto, se considera que la regularización Lasso fue la herramienta más robusta para este problema, siendo capaz de minimizar el error de predicción significativamente y, según el año, aportando parsimonia y explicabilidad. Lasso pudo filtrar mejor el ruido inherente a la encuesta EPH y evitar el colapso (que sí sufrió Ridge) ante la escasez de casos positivos.